Web scraping

- Web scraping - это процесс извлечения информации из интернета. Когда мы говорим «web scraping», подразумевается именно автоматизация этого процесса

Когда нужен скрапинг

- 1. Время на написание скрипта меньше, чем время, потраченное на эту же работу без скрипта.
- 2. Важна скорость получения результата.
- 3. Необходимо дождаться наступления определенного события.

Проблемы при скрапинге

- Огромное многообразие сайтов.
- Сайты постоянно меняются.
- Сайты с динамически формируемым контентом.

Инструменты для скрапинга

- 1. Developer Tools в браузере.
- 2. Requests.
- 3. Beautiful Soup.
- 4. Requests-html.
- 5. Selenium.

Как открыть Developer Tools

Developer Tools можно открыть несколькими способами:

- F12;
- ПКМ -> Inspect/Просмотреть код;
- Сочетания клавиш, например: Ctrl + Shift + I.

Инструменты на python

Инструмент	Как установить	Описание
requests	pip install requests	извлечение сырой разметки
Beautiful Soup	pip install beautifulsoup4	удобная библиотека для легкого извлечения данных из сырой разметки
requests-html	pip install requests-html (только python 3.6+)	извлечение сырой разметки на сайтах с динамически формируемым контентом + удобное извлечение данных из полученной разметки
selenium	pip install selenium + нужен драйвер	эмулятор браузера или даже полноценный браузер (в зависимости от драйвера)

Извлечение информации

- 1. Всегда начинаем с изучения особенностей целевого сайта! Возможно, там есть удобный API или можно вытянуть информацию через тот же механизм, что и сам сайт (это тоже API, только не публичный).
- 2. Если никакого API нет, то переходим к плану Б.

Практика

Домашнее задание

- Необходимо парсить страницу со свежими статьями (https://4pda.to/) и вывести название статьи и дату публикации.

Документация

- BeautifulSoup:

https://www.crummy.com/software/BeautifulSoup/bs4/doc.ru/bs4ru.html

- Selenium:

https://habr.com/ru/post/248559/